

Conhecimento e Raciocínio

Aula 4

Lógica Difusa

Viriato A.P. Marinho Marques

DEIS - ISEC

2020 / 2021



9.1 Métodos de Representação

9.1 Métodos de Representação

1. Probabilidade

1. Redes Bayesianas
2. Árvores de Decisão Bayesianas (PROSPECTOR)
3. Cadeias de Markov

2. Teoria de Dempster-Shaffer

3. Factores de Certeza (*Certainty Factors - CF*)

1. MYCIN
2. CLIPS
3. EXSYS: Soma, Multiplicação, Max, Min, Média, Mycin...

4. Lógica Difusa

1. Inferência de **Mamdani** / *JFS freeware*
2. Regra Composicional de Inferência / *Sistema CADLAG-2*
3. *Fuzzy Pattern Matching* / *Fuzzy CLIPS*

Módulo II

9.2 Conjuntos Difusos

9.2 Conjuntos Difusos

O conceito de **Conjunto Difuso** foi introduzido por L.A. Zadeh nos anos 60. Com base neste conceito surgiram posteriormente:

- **Números e Intervalos Difusos**
- **Computação com Palavras** (*Computing with Words - CW*)
- **Teoria da Possibilidade**
- **Lógica Difusa.**

A Lógica Difusa provou ser uma base de trabalho muito consentânea com a realidade. É utilizada com grande sucesso como base de processos de inferência em

- **Sistemas de Controlo**
- **Sistemas Periciais**

9.2 Conjuntos Difusos

Conjunto Difuso: Um conjunto a que cada elemento pode pertencer “não completamente” mas apenas “parcialmente”

- O grau de pertença é expresso por um número ou por uma função $\mu(x)$
- Varia entre 0 e 1.

Formalmente:

- Se X é uma colecção de objectos denotados genericamente por x , um **conjunto difuso** \tilde{A} definido em X é um conjunto de pares ordenados da forma

$$(x, \mu_{\tilde{A}}(x)) \quad \mu_{\tilde{A}}(x) \in [0,1]$$

- A função μ chama-se Função de Pertença
- Representa o grau de pertença do elemento x ao conjunto difuso

Exemplo

Conjunto de inteiros próximos de 1: $\tilde{A} = \{(0,0.5), (1,1), (2,0.5), (3,0.25)\}$

9.2 Conjuntos Difusos

A Função de Pertença pode ser contínua:

- Neste caso o conjunto difuso representa-se na forma $\tilde{A} = (x, \mu_{\tilde{A}}(x))$

Exemplo

Conjunto de reais próximos de 25

$$\tilde{A} = \{x, \mu(x) \mid \mu(x) = 1/[1 + (x - 25)^2]\}$$

(Portanto, se $x=25$, $\mu=1$)

Operações com Conjuntos Difusos

Segundo Zadeh:

- | | | |
|------------------|--|---|
| • Intersecção | $\tilde{C} = \tilde{A} \cap \tilde{B}$ | $\mu_{\tilde{C}}(x) = \min\{\mu_{\tilde{A}}(x), \mu_{\tilde{B}}(x)\}$ |
| • Reunião | $\tilde{D} = \tilde{A} \cup \tilde{B}$ | $\mu_{\tilde{D}}(x) = \max\{\mu_{\tilde{A}}(x), \mu_{\tilde{B}}(x)\}$ |
| • Complementação | $\tilde{E} = \neg \tilde{A}$ | $\mu_{\tilde{E}}(x) = 1 - \mu_{\tilde{A}}(x)$ |

NOTA: Portanto, dado um Universo U, um seu elemento que não figure num conjunto nele definido, deverá aparecer no seu complementar com grau de pertença 1.

9.2 Conjuntos Difusos

Portanto:

- $A \cap B$

Elementos comuns a A e B sendo μ de cada um $\mu_{A \cap B} = \min(\mu_A(x), \mu_B(x))$

- $A \cup B$

Elementos comuns e não comuns a A e B sendo $\mu_{A \cup B} = \max(\mu_A(x), \mu_B(x))$

- $/A$

Todos os elementos do **Universo** de A, sendo μ de cada um $\mu_{/A} = 1 - \mu_A$

Exemplos

- Seja X o conjunto de modelos de casas possíveis, considerando o número de quartos de 1 a 10.
- Seja $\mu(x)$ a função de pertença de \tilde{A} , definida pela condição difusa "*a casa do tipo x é confortável para uma família de 4 pessoas*":

$$\tilde{A} = \{(1,0.2), (2,0.5), (3,0.8), (4,1), (5,0.7), (6,0.3)\}$$

9.2 Conjuntos Difusos

Dados \tilde{A} e \tilde{N}

$$\begin{aligned}\tilde{A} &= \text{Casas confortáveis para 4 pessoas} = \\ &= \{(1,0.2), (2,0.5), (3,0.8), (4,1), (5,0.7), (6,0.3)\}\end{aligned}$$

$$\begin{aligned}\tilde{N} &= \text{Casas grandes} = \\ &= \{(3,0.2), (4,0.4), (5,0.6), (6,0.8), (7,1), (8,1), (9,1), (10,1)\}\end{aligned}$$

os seguintes conjuntos difusos têm os respectivos significados:

$$\begin{aligned}\text{Casas grandes E confortáveis para 4 pessoas} &= \\ &= \tilde{A} \cap \tilde{N} = \\ &= \{(3, 0.2), (4,0.4), (5,0.6), (6,0.3)\}\end{aligned}$$

$$\begin{aligned}\text{Casas grandes OU confortáveis para 4 pessoas} &= \\ &= \tilde{A} \cup \tilde{N} = \\ &= \{(1,0.2), (2,0.5), (3,0.8), (4,1), (5,0.7), (6,0.8), (7,1), (8,1), (9,1), (10,1)\}\end{aligned}$$

$$\begin{aligned}\text{Casas pequenas} &= \\ &= / \tilde{N} = \\ &= \{(1,1), (2,1), (3,0.8), (4,0.6), (5,0.4), (6,0.2)\}\end{aligned}$$



9.3 Números Difusos

9.3 Números Difusos

Um Número Difuso \tilde{N} representa um valor aproximado de N , em que N se chama Valor Médio

- A função de pertença de um número difuso tem apenas um máximo, e sempre de valor 1
- As funções de pertença normalmente utilizadas para números difusos são triangulares
- As trapezoidais usam-se para Intervalo Difusos.


Exemplo

Fuzzy Number (cerca de) 49:


$$\sim 49 = \{(x, \mu_{\sim 49}(x)) \mid x \in \mathbb{R}, \mu_{\sim 49}(x)\}$$

Aproximação

\Rightarrow



9.3 Números Difusos



Na notação LR (Left-Right) são dados B, C e as aberturas α e β

A notação **Alfa-Cut** é aplicável **apenas** a funções de pertença trapezoidais (e triangulares) e simplifica muito os cálculos:

- Um intervalo difuso é representado pelas 4 abscissas A, B, C e D dos pontos em que $\mu=0$, $\mu=1$, $\mu=1$ e $\mu=0$ (trapézios).
- Para um número difuso de forma triangular, $B=C$

Operações Aritméticas

Por aplicação do chamado Teorema da Extensão, as operações com **Números Crespos** (*Crisp Numbers*) podem ser estendidas aos **Números Difusos**:

9.3 Números Difusos

O cálculo pela definição é muito moroso:

Exemplo

Adição: $\mu_{\tilde{A} \oplus \tilde{N}} = \sup_{z=x+y} \min [\mu_{\tilde{A}}(x), \mu_{\tilde{N}}(y)]$

Sejam os números difusos \tilde{A} e \tilde{N}

Para cada x_i de \tilde{A}

Para cada y_j de \tilde{N}

Calcular $z_i = x_i + y_j$

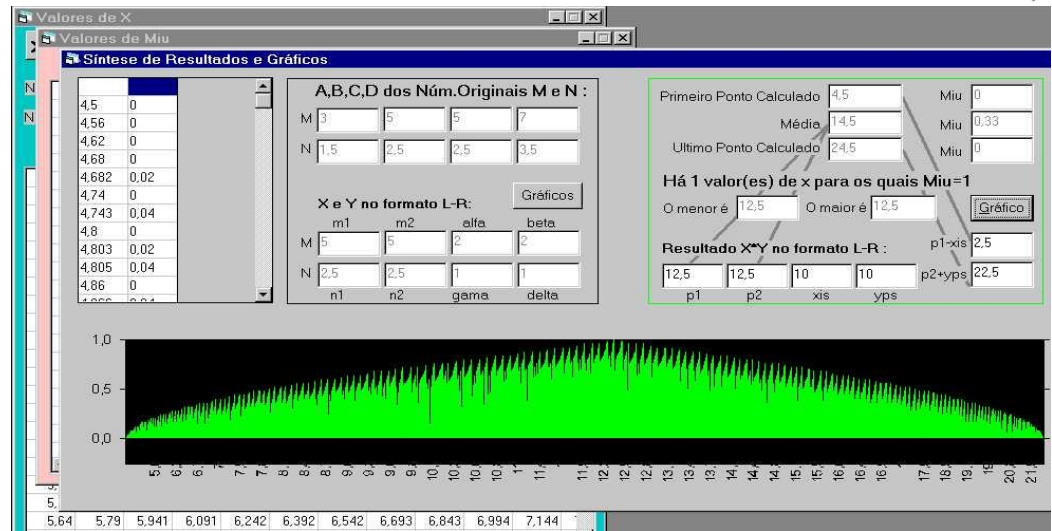
Calcular $\min(\mu(x)_i, \mu(y)_j)$

Fim Para

Para cada z_i

Determinar $\mu(z)_j = \max(\mu(z)_i)$

Resultado: O conjunto dos $\{z_i, \mu(z)_i\}$



Prós:

- Funciona para qualquer forma de função de pertença

Contras:

- Muito moroso
- Obriga a discretizar as funções de pertença contínuas

Aspecto gráfico da
adição de dois
números difusos
executada pela
definição

9.3 Números Difusos

As operações na notação Alfa-Cut ou LR, com formas trapezoidais, são

- Compreensíveis a partir da aritmética de intervalos *crespos*
- Facilmente implementadas

Para intervalos crespos $[a,b]$ e $[c,d]$ os extremos dos intervalos resultantes são:

$$[a,b] + [c,d] = [a+c, b+d]$$



$$[a,b] - [c,d] = [a-d, b-c]$$

$$[a,b] * [c,d] = [\min(ac, ad, bc, bd), \max(ac, ad, bc, bd)]$$

$$[a,b] / [c,d] = [a,b] * [1/d, 1/c] = [\min(a/d, a/c, b/d, b/c), \max(a/d, a/c, b/d, b/c)]$$

$$\begin{aligned}\alpha.[a,b] &= [\alpha a, \alpha b] \quad \text{se } \alpha > 0 \\ &= [\alpha b, \alpha a] \quad \text{se } \alpha < 0\end{aligned}$$

Para efeitos de cálculo, um intervalo difuso pode ser encarado como definido pelos extremos de dois intervalos crespos:



9.3 Números Difusos

Portanto, aplicando “duas vezes” as fórmulas anteriores, obtém-se:

1. Adição:

$$(m_0, m_1, m_2, m_3) + (n_0, n_1, n_2, n_3) = (m_0+n_0, m_1+n_1, m_2+n_2, m_3+n_3)$$

2. Subtracção:

$$(m_0, m_1, m_2, m_3) - (n_0, n_1, n_2, n_3) = (m_0-n_3, m_1-n_2, m_2-n_1, m_3-n_0)$$

“o limite menor” menos “o limite maior” dá
“o limite menor” (o mais à esquerda)

Este processo
repete-se para “o
intervalo interno
[m1,m2]”

3. Multiplicação:

$$\begin{aligned} &(m_0, m_1, m_2, m_3) \times (n_0, n_1, n_2, n_3) = \\ &= (\min(m_0n_0, m_0n_3, m_3n_0, m_3n_3), \min(m_1n_1, m_1n_2, m_2n_1, m_2n_2), \\ &\quad \max(m_1n_1, m_1n_2, m_2n_1, m_2n_2), \max(m_0n_0, m_0n_3, m_3n_0, m_3n_3)) \end{aligned}$$

Simétrico para “o
limite maior”

Na multiplicação
nada se pode dizer
acerca do resultado
dos produtos.
Portanto, “os limites
menores” têm de
recorrer ao *min* ...

...e os “maiores” ao
max

4. Divisão :

$$\begin{aligned} &(m_0, m_1, m_2, m_3) / (n_0, n_1, n_2, n_3) = \\ &= (\min(m_0/n_0, m_0/n_3, m_3/n_0, m_3/n_3), \min(m_1/n_1, m_1/n_2, m_2/n_1, m_2/n_2), \max(m_1/n_1, \\ &\quad m_1/n_2, m_2/n_1, m_2/n_2), \max(m_0/n_0, m_0/n_3, m_3/n_0, m_3/n_3)) \end{aligned}$$

A divisão obtém-se a partir
da multiplicação

9.3 Números Difusos

Exemplo:

Adição e Subtração de 2 números difusos

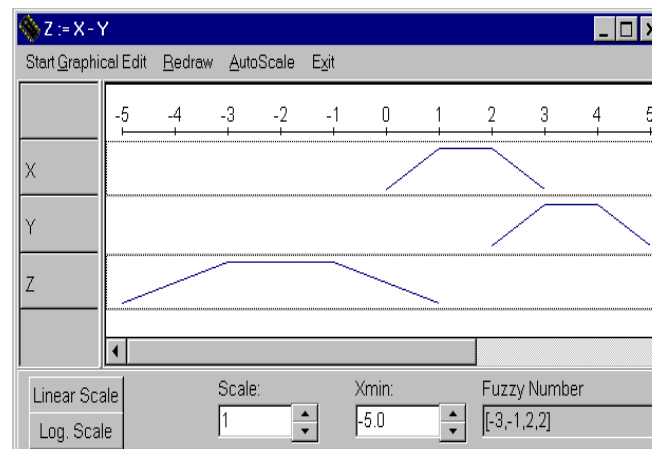
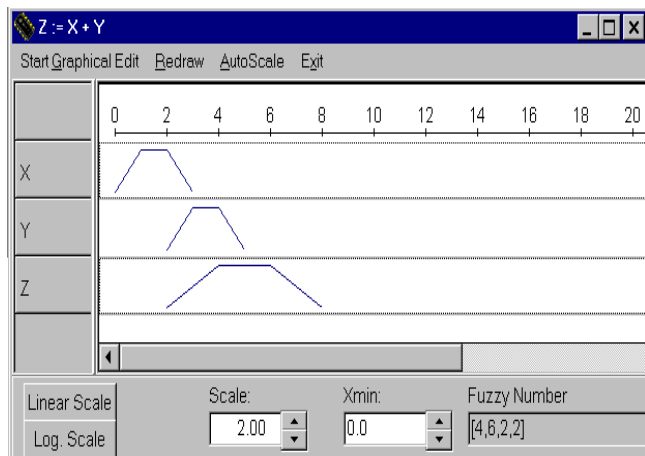

α -cut $(0,1,2,3) + (2,3,4,5) = (2,4,6,8)$

LR $(1,2,1,1) + (3,4,1,1) = (4,6,2,2)$

$(0,1,2,3) - (2,3,4,5) = (-5,-3,-1,-2)$

$(1,2,1,1) - (3,4,1,1) = (-3,-1,2,2)$

X [1,2,1,1]
Y [3,4,1,1]
Z := X + Y
Z [4,6,2,2]



9.4 Computação com Palavras


9.4 Computação com Palavras (*Computing with Words - CW*)

Conjuntos difusos podem representar termos linguísticos: basta atribuir um **valor médio** e uma **difusão** à tradução do "conceito" pretendido

Exemplo

- Velho: $\tilde{N}_{(\text{velho})} = \{(u, \mu_{\text{velho}}(u)) \mid u \in [0,100]\}$
 $\mu_{\text{velho}}(u) = 0$ se $u \in [0,50]$
 $\mu_{\text{velho}}(u) = 1 / (1 + ((u-50)/5)^{-2})$ se $u \in]50,100]$

Na aproximação por trapézios teríamos qualquer coisa deste tipo:



Neste exemplo a **Variável Linguística** "*idade*" foi adjectivada pelo termo Alta gerando o termo Velho.


9.4 Computação com Palavras

Deste modo um **vocabulário** pode ser associado a qualquer variável linguística:

- Cada termo linguístico é uma **graduação da variável**
- Cada termo linguístico é representado por um **conjunto difuso**

Exemplo:

Seja a variável **profissão** classificada em função do **rendimento** que gera. Poderia ser:



(não desenhado à escala)

A classificação é subjectiva: pode recorrer-se a estatísticas e existem métodos para desenhar os conjuntos difusos a partir dos resultados obtidos *(ver Zimmerman)*

9.4 Computação com Palavras



Numa escala unitária, de modo semelhante, podem também representar-se:

- **Quantificadores:** Todos, quase todos...alguns...nenhum
- **Qualificadores de Frequência:** Sempre,...Por Vezes...Nunca

Além de qualificadores e quantificadores, a linguagem comum recorre a **Modificadores** (*hedge modifiers*):

- **Muito:** É normalmente traduzido pela **função condensação**, que eleva ao quadrado a função μ do termo original:

$$\mathbf{Muito(velho)} = \{(u, \mu_{\text{velho}}^2(u)) \mid u \in [0,100]\}$$

$$\mu_{\text{velho}}(u) = 0 \text{ se } \mu \in [0,50]$$

$$\mu_{\text{velho}}(u) = 1 / (1 + ((u-50)/5)^{-2})^2 \text{ se } \mu \in]50,100]$$

- **Aproximadamente ou Cerca de:** É normalmente traduzido pela **função dilatação**, que calcula a raiz da função μ do termo original:

$$\mathbf{Aproximadamente(velho)} = \{(u, \mu_{\text{velho}}^{1/2}(u)) \mid u \in [0,100]\}$$

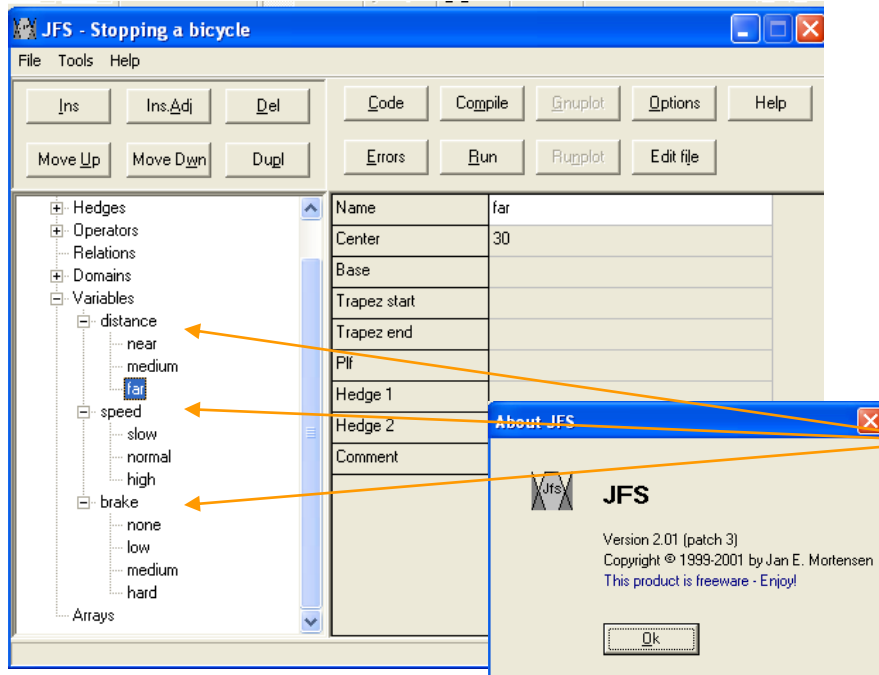
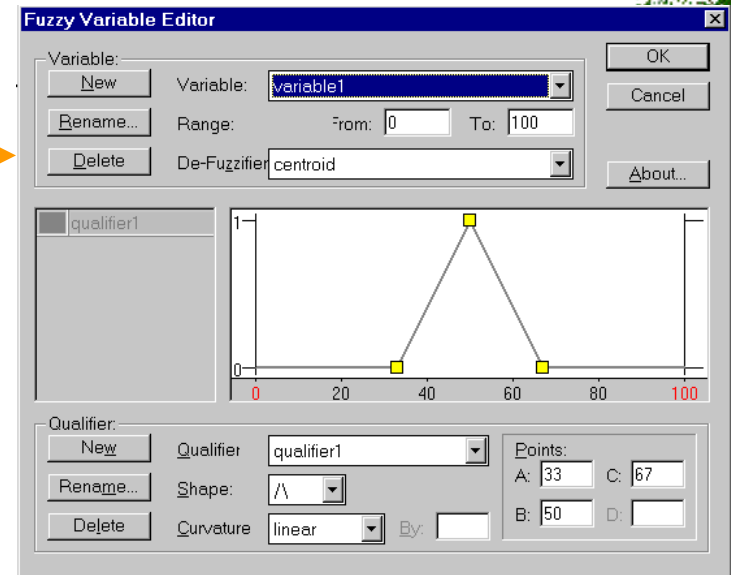
$$\mu_{\text{velho}}(u) = 0 \text{ se } \mu \in [0,50]$$

$$\mu_{\text{velho}}(u) = 1 / (1 + ((u-50)/5)^{-2})^{1/2} \text{ se } \mu \in]50,100]$$

9.4 Computação com Palavras

Exemplo: FLINT (Uma ferramenta do LPA-Prolog)

Definição das funções de
pertença de Termos
Linguísticos usando uma
opção do FLINT



Exemplo: JFS (*freeware*)

Controlar a travagem de um veículo
Definição de termos linguísticos como
gradações das variáveis *distância*, *velocidade*
e *intensidade de travagem*

9.5 Inferência Difusa

9.5 Inferência Difusa

Com conjuntos, números difusos e termos linguísticos, torna-se fácil representar regras **If...Then** em correspondência directa com a realidade. Duas aplicações típicas são Sistemas de Controlo e Sistemas Periciais:

Sistemas Periciais:

- **Diagnóstico:** SE a febre é muito(alta) e a tosse é seca ENTÃO é gripe
- **Crédito:** SE o rendimento é (baixo OU muito(baixo)) OU
SE o rendimento é (médio OU alto) E o débito é muito alto
ENTÃO o risco é grande

Sistemas de Controlo:

- **ABS:** SE roda bloqueada ENTÃO eliminar pressão no disco
SE roda por vezes(bloqueda) ENTÃO diminuir pressão
- **Caldeira:** SE temperatura alta E pressão alta
ENTÃO baixar muito a alimentação de gás

9.5 Inferência Difusa



Têm sido definidos várias inferências, em si. Vamos ver duas:

- A **Inferência de Mandani**, muito usada em sistemas de controlo
- A **Regra Composicional de Inferência** (RCI), de Zadeh, usada p.e. em sistemas de diagnóstico

Qualquer dos métodos permite obter conclusões com um *grau de verdade* variável, em função dos graus de verdade da premissa.

Exemplo:

SE o **rendimento** é **baixo** E o débito é **muito(alto)** ENTÃO o risco é **grande**

Premissa:

Duas cláusulas cujos valores de μ (termo “rendimento baixo” e “débito muito(alto)”) expressam “quanto o rendimento é baixo” e “o débito é alto”

Conclusão:

Alguma forma de expressar “quanto o risco é grande”

9.5 Inferência Difusa

Note-se que:

- A semântica “*quanto o rendimento é baixo*” é a mesma de “*quanto é verdadeiro que o rendimento seja baixo*”
- A semântica “*quanto o débito é alto*” é a mesma de “*quanto é verdadeiro que o débito seja alto*”
- A semântica “*quanto o risco é grande*” é a mesma de “*quanto é verdadeiro que o risco seja grande*”

Estamos em presença de um tipo de lógica no qual, entre verdadeiro e falso, se admite a existência de graduações:

- As inferências são feitas com base em termos linguísticos
- A incerteza inerente a este tipo de representações e o **Raciocínio Aproximado** (*approximate reasoning*) nada tem a ver com probabilidade. Esta incerteza expressa **possibilidade**

De termos linguísticos, graus de verdade e possibilidade, derivam a **Lógica Difusa** e a **Teoria da Possibilidade**.

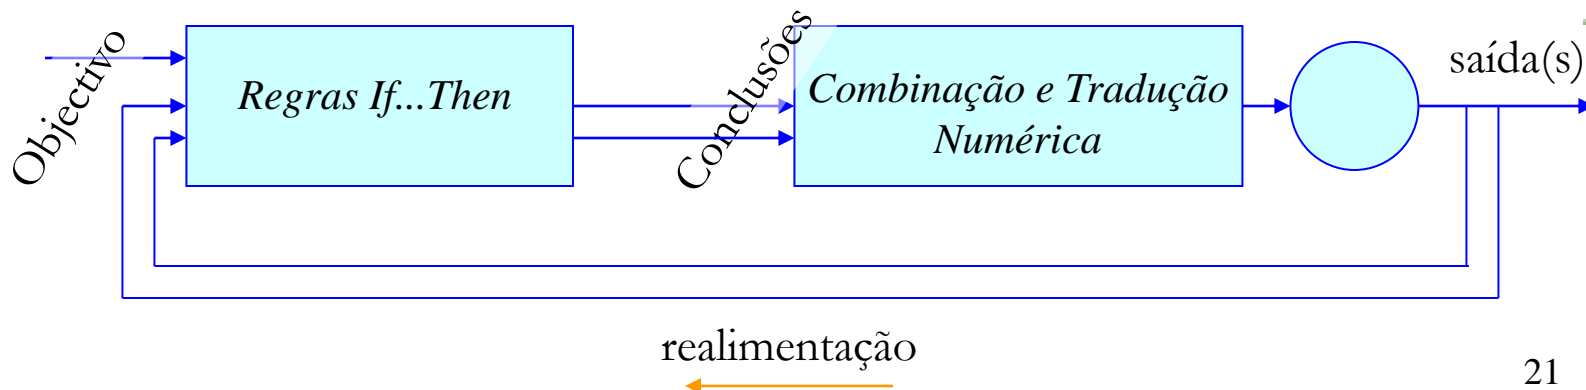


9.5.1 Inferência de Mamdani

9.5.1 Inferência de Mamdani

Num sistema de controlo os sinais de erro, numéricos, representam uma diferença entre o objectivo pretendido e a saída actual:

- 1) Para realizar as inferências com base em termos linguísticos, os sinais de erro são transformados em termos linguísticos
- 2) Realiza-se uma inferência para cada regra IF...THEN
- 3) O resultado de cada uma tem de ser combinado num único conjunto difuso
- 4) Esse conjunto difuso tem de ser transformado num valor numérico para aplicação aos actuadores




9.5.1 Inferência de Mamdani

Na inferência segundo Mamdani o μ da **conclusão** obtém-se **cortando o termo linguístico do consequente** pelo valor de μ do **antecedente**

- Se houver mais que 1 antecedente (ligados pelo operador E) determina-se o mínimo desses μ

Exemplo: Num sistema de controlo de velocidade de um motor, suponhamos que 200r.p.m. corresponde a um *erro positivo baixo* e que a regra é

“Se erro positivo baixo então diminuir muito pouco a velocidade”



9.5.1 Inferência de Mamdani

Exemplo: Inferência de Mandani num Fuzzy ES

Suponhamos um ES destinado a calcular o limite de crédito a conceder a um cliente de um banco. Sejam 4 regras:

1. SE o candidato é novo E o rendimento é baixo ENTÃO o crédito é baixo
2. SE o candidato tem outros créditos, ENTÃO o crédito é baixo
3. Se o candidato tem bens próprios, ENTÃO o crédito é alto
4. Se o candidato sofre de doença crónica, ENTÃO o crédito é médio

Fuzzificação

Regra 1:	Fuzzificar idade do candidato (dada em anos)	$\mu(\text{idade})=0,8$
	Fuzzificar rendimento (dado em \$/mês)	$\mu(\$)=0,2$
Regras 2, 3 e 4:	Fuzzificadas por método análogo	

Inferência

Regra 1:	A condição E é avaliada como $\min(\mu(\text{idade}), \mu(\$))=\min(0.8,0.2)=0,2$ Obtém-se assim $\mu(\text{Regra1})=0,2$ porque o termo crédito baixo é “cortado” por $\mu(\text{Regra1})$, o <i>min</i> de entre os dois
Regras 2, 3 e 4:	O valor de outros créditos, bens próprios e gravidade da doença crónica são fuzzificados pelo mesmo processo. Suponhamos que para a regra 2. se obteve $\mu(\text{Regra2})=0,3$

9.5.1 Inferência de Mamdani

Agregação

As regras 1 e 2 têm a mesma conclusão (crédito baixo). O operador subentendido entre elas é o OU:

1. SE o candidato é novo E o rendimento é baixo ENTÃO o crédito é baixo
- OU
2. SE o candidato tem outros créditos, ENTÃO o crédito é baixo

Como se trata de uma disjunção, entre as conclusões geradas por uma e outra determina-se $\mu(1,2) = \max(\mu(\text{Regra1}), \mu(\text{Regra2})) = \max(0.2, 0.3) = 0.3$

O conjunto de operações **min** e **max** utilizadas para interpretar as regras 1. e 2. designa-se por Método MAX-MIN: o **min** é utilizado nos antecedentes e o **max** na agregação de conclusões de duas (ou mais) regras que têm igual conclusão


Desfuzzificação

As regras 1 e 2 geraram um único termo conclusão (**crédito baixo cortado a 0.3**). Suponhamos que:

- A regra 3 gerou como conclusão **crédito alto cortado a 0.7**
- A regra 4 gerou como conclusão **crédito médio cortado a 0.5**



9.5.1 Inferência de Mamdani



Para determinar o crédito a conceder, estas conclusões têm de ser combinadas num só número crespo final. É isto a **Desfuzzificação**.

O método mais usado é o **COA** (*Center of Area*) ou Centróide. Consiste em determinar a **abscissa do baricentro**. As dimensões do resultado são \$ e portanto representa o valor do crédito a conceder.

Para μ discreta:

$$\mathfrak{R} = \frac{\sum_{i=0}^n d_i \cdot \mu_A(d_i)}{\sum_{i=0}^n \mu_A(d_i)}$$

Para μ contínua:


$$\mathfrak{R} = \frac{\int_{u1}^{u2} u \cdot \mu(u) du}{\int_{u1}^{u2} \mu(u) du}$$

μ =abscissas

9.5.1 Inferência de Mamdani

O COA representa o Centro de Gravidade de uma figura geométrica:

- Neste caso pretendemos o Centro de Gravidade da figura delimitada pelo azul claro, que representa a conclusão das regras 1 a 4.
- Este centro de gravidade é uma abscissa x : Ela representa o valor do crédito a conceder
- Note-se que, como Alto possui maior massa (tem valores de μ mais altos) é de esperar que o COA obtido se situe acima do ponto médio (1000)



Como os trapézios são simétricos e o corte superior é plano, podemos calcular uma aproximação de COA designada por Weighted Average. Para cada trapézio tem-se

média(Baixo)=500

média(Médio)=1000

média(Alto)=1500

... e depois combinam-se os valores assim obtidos:

$$\text{Crédito} = \frac{500 \times 0.3 + 1000 \times 0.5 + 1500 \times 0.7}{0.3 + 0.5 + 0.7} = 1333.33 \text{ €}$$

9.5.2 Regra Composicional de Inferência

9.5.2 Regra Composicional de Inferência (RCI - *Zadeh*)

A Regra Composicional de Inferência baseia-se em **Relações Difusas**

- Sejam as seguintes relações:

Relação Crespa “X é casado com Y”

Só utiliza 0's e 1's
(verdadeiro / falso)

É casado com	Carla	Jacinta	Maria
João	1	0	0
Manuel	0	1	0
Luís	0	0	1

Relação Difusa “X é muito maior que Y”

Utiliza Graus de
Pertença à Relação

X >> Y	1	2	3
3	0.2	0.05	0
20	1	0.9	0.85
89	1	1	1

9.5.2 Regra Composicional de Inferência

Uma relação difusa pode ser dada por uma tabela ou por uma função:

Exemplo

A seguinte função pode traduzir a relação “*x é bastante maior que y*”

0 se $x \leq y$

$\mu_{\sim R}(x,y) = (x-y)/10y$ se $y < x \leq 11y$

1 se $x > 11y$

A RCI permite efectuar inferências a partir de duas relações difusas, recorrendo à operação de **Composição de Relações**. Cada inferência equivale a um ***Modus Ponens Generalizado***:

Premissa: S_1 is Q_1

Implicação: $S_1 \sim R S_2$

Conclusão: S_2 is Q_2

em que $\sim R$ é uma relação difusa

9.5.2 Regra Composicional de Inferência

Exemplo

MPG (exemplo do Zimmerman):

SE o tomate está vermelho ENTÃO está maduro
O tomate está amarelado

O tomate está pouco maduro

Exemplo

Aplicação ao Diagnóstico:

SE o sintoma é $\{X\}$ ENTÃO o diagnóstico é Y
O sintoma é semelhante a $\{X\}$ num grau λ_1

O diagnóstico é Y num grau λ_2

Composição de Relações Difusas (Zadeh):

$$R_1 \circ R_2 = \left\{ \left[(x, z), \max_y \{ \min \{ \mu_{R_1}(x, y), \mu_{R_2}(y, z) \} \} \right] \mid x \in X, y \in Y, z \in Z \right\}$$

9.5.2 Regra Composicional de Inferência

Exemplo

Seja o universo $X = \{1, 2, 3, 4\}$

Seja $\sim R1 = "x \text{ é pequeno}" = \{(1,1), (2,.6), (3,.2), (4,0)\}$

Seja $\sim R2 = "x \text{ e } y \text{ são aproximadamente iguais}"$

A Composição de Relações obtém-se (quase) como uma multiplicação de matrizes (o número de colunas da primeira matriz tem de ser igual ao número de linhas da segunda) :

$$\{(1,1), (2,.6), (3,.2), (4,0)\} \circ \begin{array}{c|cccc} x \backslash y & 1 & 2 & 3 & 4 \\ \hline 1 & 1 & .5 & 0 & 0 \\ 2 & .5 & 1 & .5 & 0 \\ 3 & 0 & .5 & 1 & .5 \\ 4 & 0 & 0 & .5 & 1 \end{array} =$$

$$= \begin{array}{c|cccc} & 1 & 2 & 3 & 4 \\ \hline \text{Max}(\min(1,1), \min(.6,.5), \min(0,2), \min(0,0)) & \text{max}(\min(1,.5), \min(.6,1), \min(.2,.5), \min(0,0)) & \text{max}(\min(1,0), \min(.6,.5), \min(.2,1), \min(0,.5)) & \text{max}(\min(1,0), \min(.6,0), \min(.2,.5), \min(0,1)) \end{array}$$

$$= \begin{array}{c|cccc} & 1 & 2 & 3 & 4 \\ \hline y & 1 & .6 & .5 & .2 \end{array}$$

A relação resultado traduz ***“y é aproximadamente pequeno”***. Note-se que para “3” e “4” o valor μ subiu devido à “dilatação” originada pelo termo “aproximadamente” que em $\sim R1$ não existia.

9.6 Possibilidade e Lógica Difusa

9.6.1 Possibilidade e Necessidade

Possibilidade: uma forma de incerteza que exprime uma avaliação (eventualmente *) subjectiva acerca de certa questão

Exemplos

1. Uma pessoa é “nova” ou “velha” mas não se sabe exactamente a sua idade
2. Um forno está “quente” ou “frio” mas não se sabe exactamente a sua temperatura
3. Num semáforo:
 - A probabilidade de verde, amarelo e vermelho é p.e. $5/10$, $1/10$ e $4/10$
 - A possibilidade de verde, amarelo ou vermelho é 1 (para qualquer das cores) porque se sabe que é “completamente possível” que a cor visível seja uma destas

Dado um conjunto difuso, a possibilidade de um valor x é numericamente igual a $\mu(x)$

(*) No CADIAG-2 o autor defende que no domínio do diagnóstico possibilidade e probabilidade têm o mesmo valor. Normalmente possibilidade $>$ probabilidade.

9.6.1 Possibilidade e Necessidade

Proposições da forma “ x é \tilde{F} ”, em que x é um **objecto**, implicitamente contêm uma referência a um **atributo** A do **objecto** X (i.e. são representáveis por ternos **OAV** em que **valor** é um *conjunto difuso* que representa um *termo linguístico*)

Exemplo

“a água está quente” é equivalente a “a temperatura da água é alta”, em que “temperatura” é um **atributo** do **objecto** “água” e **alta** o valor desse atributo.

A Equação de Atribuição Relacional (**RAE**) de Zadeh formaliza este processo de atribuição, baseando-se numa relação difusa $\sim R$:

$$\tilde{R}(A(X)) = \tilde{F}$$

A RAE induz uma distribuição de possibilidade cuja função de distribuição, $\pi_x(u)$, tem valores numericamente iguais aos da função de pertença que define o termo linguístico. Ou seja:

$$\pi_x \hat{=} \mu_{\tilde{F}}(u)$$

em que o símbolo “ $\hat{=}$ ” significa “é definida como”.

9.6.2 Variável Linguística Verdade

A **necessidade**, N , está intimamente relacionada com a possibilidade:

$$\pi(\tilde{A}) = 1 - N(\not\subset \tilde{A})$$


- Possibilidade e Necessidade são **Medidas Difusas**
- A necessidade é “mais exigente” e restritiva no sentido em que **mede quão necessariamente um facto é possível**, em função de outro conhecido.
- $N=1$ indica que um facto é "necessariamente verdadeiro"

9.6.2 Variável Linguística Verdade

De todas as variáveis linguísticas, uma assume particular importância: a variável **Verdade**

Admitindo graduações desta variável (*completamente falso, falso ... pouco verdadeiro, verdadeiro, completamente verdadeiro*) diferencia-se claramente a lógica clássica da lógica difusa: agora há graus de verdade expressos por termos linguísticos que são representáveis por conjuntos difusos.

9.7 Sistema Pericial CADIAG-2



Termos da variável linguística "verdade" segundo Baldwin

$$\mu_{\text{Muito Verdadeiro}} = (\mu_{\text{Verdadeiro}}(v))^2$$

$$\mu_{\text{Aproximada mente Verdadeiro}} = (\mu_{\text{Verdadeiro}}(v))^{1/2}$$

9.7 CADIAG-2

A teoria dos conjuntos difusos, possibilidade e composição de relações permitem tratar os quadros médicos, inerentemente inexactos, de forma adequada:

- Suportam aproximações linguísticas dos termos médicos
- Suportam métodos de raciocínio aproximado através da lógica difusa

O CADIAG-2 (*Computer Assisted Diagnosis*) é um Sistema Pericial de Diagnóstico Médico baseado em na Teoria da Possibilidade e na Composição de Relações Difusas.

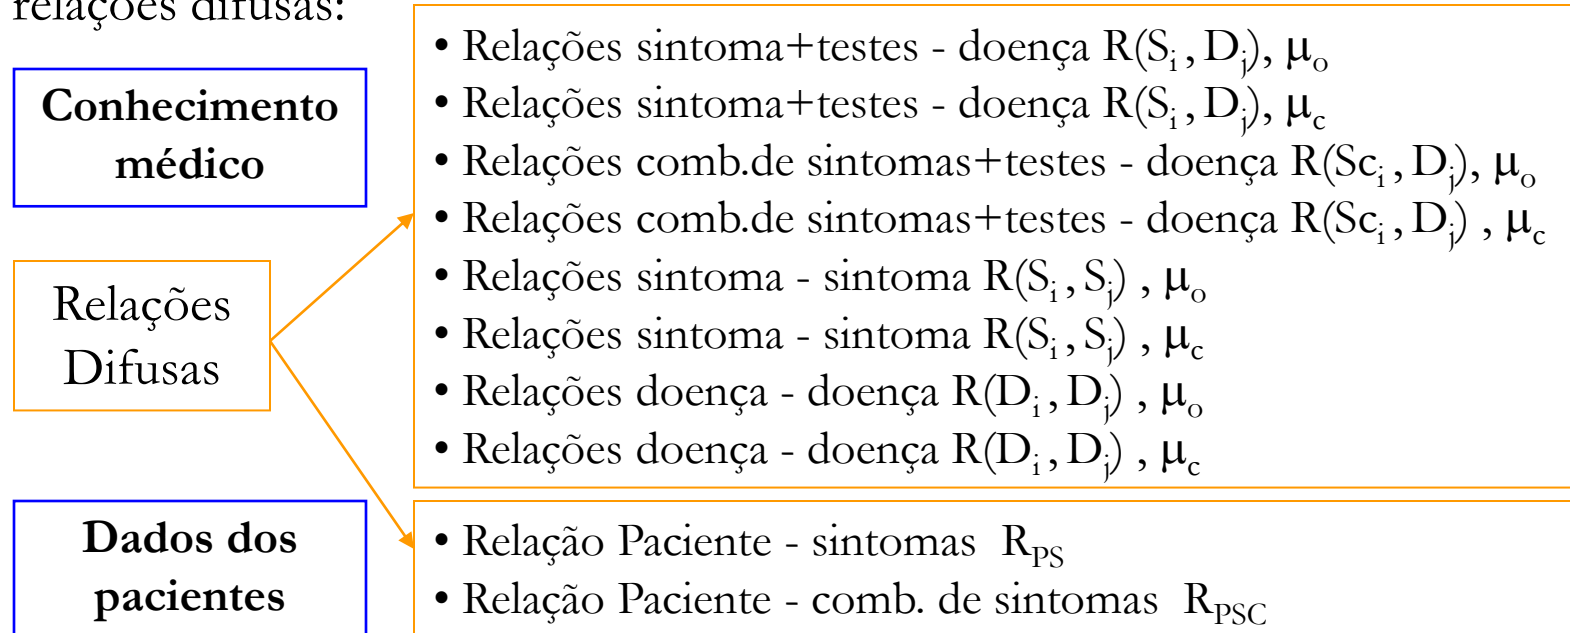
9.7.2 CADIAG-2: Conhecimento

Fuzzy Set Theory in Medical Diagnosis, *Adlassnig, K.P.*

IEEE Transactions on Systems, Man and Cybernetics Vol.SMC-16, N°2, March/April 1986.

9.7.2 CADIAG-2: Representação do Conhecimento

Conhecimento médico e dados dos pacientes são representados por 8 relações difusas:



o = grau de ocorrência = probabilidade de sintoma suposto doença (*a priori*)

c = grau de confirmabilidade = probabilidade de doença suposto sintoma (*a posteriori*)

Probabilidades iniciais obtidas por análise de históricos e experiência médica.

9.7.2 CADIAG-2: Conhecimento


Exemplo: Fuzzificação de Sintomas

Suponhamos que o paciente fez uma análise ao nível de potássio. O resultado é guardado no *Medical Information System* como valor crespo, por exemplo 5.3 mmol/l. O interpretador difuso, *Fuzzy Interpreter of Patient Data*, traduz este valor para os sintomas

potássio muito reduzido
potássio reduzido
potássio normal
potássio elevado
potássio muito elevado

$$\left. \begin{array}{l} \mu_{S_i} = 0.0 \\ \mu_{S_i} = 0.0 \\ \mu_{S_i} = 0.4 \\ \mu_{S_i} = 0.6 \\ \mu_{S_i} = 0.0 \end{array} \right\}$$

Fuzzificação



Trata-se de uma fuzzificação: um valor crespo é representado por um valor μ de um termo de uma variável linguística.

- A relação assim obtida chama-se R_{PS} (de patient/symptom) e pertence ao produto cartesiano do conjunto de pacientes Π pelo conjunto de sintomas, Σ . Portanto, $R_{PS} \subset \Pi \times \Sigma$, em que $\mu_{R_{PS}}(P_q, S_i) = \mu_{S_i}$ para cada paciente P_q . O valor de $\mu \in [0,1]$ é determinado conforme exemplo acima.
- Caso um determinado teste não tenha sido efectuado, μ toma o valor v significando "desconhecido". Portanto, $\mu \in [0,1] \cup v$.

9.7.2 CADIAG-2: Conhecimento



Exemplo: Relação Paciente - Sintomas

Pacientes =

$$= \Pi = \{\text{João, Manuel}\} = \{J, M\}$$

Sintomas =

$$= \Sigma = \{\text{hipotermia, temp.normal, febre alta, febre muito alta, potássio reduzido, potássio elevado, potássio muito elevado}\}$$

$$R_{PS} = \Pi \times \Sigma$$

$$= \{(J, \text{hipotermia}), 0.0; (J, \text{temp.normal}), 0.1; (J, \text{febre alta}), 0.8; (J, \text{febre muito alta}), 0.3; (J, \text{potássio reduz.}), 0.0; (J, \text{potássio elevado}), 0.5; (J, \text{potássio mt.elevado}), 0.0; (M, \text{hipotermia}), 0.0; (M, \text{temp.normal}), 1.0; (M, \text{febre alta}), 0.0; (M, \text{febre muito alta}), 0.0; (M, \text{potássio reduz.}), 0.0; (M, \text{potássio elevado}), 0.5; (M, \text{potássio mt.elevado}), 0.0 \}$$

(os termos com grau de pertença 0 não são, na prática, representados)

O CADIAG utiliza ainda relações R_{PSC} de Pacientes / Combinações de Sintomas que provêm dos sintomas actuais, análises e história clínica:

dores nas costas \wedge limitação do movimento de coluna \wedge ... \wedge sexo masculino \wedge idade entre 20 e 40 anos

9.7.3 CADIAG-2: Inferência

9.7.3 CADIAG-2: Inferência

O objectivo (*goal*) último do sistema é concluir qual o grau de pertença de cada diagnóstico em consideração, a cada paciente.

Esta "associação" entre pacientes e diagnósticos também é traduzida por uma relação difusa R_{PD} , (de *patient/diagnostic*) definida em $R_{PD} \subset \Pi \times \Delta$, sendo Δ o conjunto dos diagnósticos possíveis, D_j . Na relação R_{PD} :

- $\mu_{R_{PD}}$ representa o grau de pertença do diagnóstico D_j ao paciente P_q
- Se um diagnóstico tem $\mu=1.0$, está confirmado
- Se tem $\mu=0.0$ está excluído
- Entre 0 e 1, μ traduz o grau de possibilidade de cada diagnóstico
- Se $\mu=\nu$, isso indica que este diagnóstico não foi considerado

Exemplo: Relação Paciente - Diagnóstico

$R_{PD} = \{(J, \text{gripe}), 0.8; (J, \text{amigdalite}), 0.3; (J, \text{sinusite}), 0.2; (M, \text{gripe}), 0.0; (J, \text{amigdalite}), 0.5; (J, \text{sinusite}), 0.1\}$

Os valores de μ exprimem quanto o CADIAG concluiu que os sintomas do João e do Manuel sugerem que se trata de gripe, amigdalite ou sinusite.

9.7.3 CADIAG-2: Inferência

As regras são do tipo

IF antecedent THEN consequent WITH (o,c)

- o = frequência de ocorrência: traduz a frequência com que o sintoma X ocorre quando a doença Y está presente **causas \rightarrow sintomas**
- c = grau de confirmabilidade: traduz o grau em que a presença do sintoma X significa a presença da doença Y **sintomas \rightarrow causas**

o e c são pois aproximações (representadas por frequências relativas) de probabilidades *a priori* e *a posteriori*

ocorrência	$= p(Y X) = p(Y \cap X)/p(X)$	<i>a priori</i>
confirmabilidade	$= p(X Y) = p(Y \cap X)/p(Y)$	<i>a posteriori</i>

Estas aproximações são adquiridas:

1. Por avaliação numérica ou linguística dada por peritos médicos
2. Por avaliação estatística de uma base de dados contendo os dados dos pacientes com diagnósticos já confirmados

9.7.3 CADIAG-2: Inferência

O CADIAG utiliza pois Relações Difusas e sua composição para inferir baseado em factores de base probabilística. Isto é possível ?

De facto, probabilidade e possibilidade são diferentes. Veja-se por exemplo que:

- $p(A \cap B) = p(A | B) / p(B)$ para probabilidade
- $\mu(A \cap B) = \min(\mu_A, \mu_B)$ para possibilidade

É possível porque o autor do CADIAG-2 admite que

"As relações do CADIAG-2 têm a importante propriedade de poderem ser interpretadas probabilisticamente. Os valores da **frequência de ocorrência** μ_o e do **grau de confirmabilidade** μ_c são definidos da seguinte forma:

$$\mu_o = \frac{F(S_i \cap D_j)}{F(D_j)} \qquad \mu_c = \frac{F(S_i \cap D_j)}{F(S_i)}$$

em que F representa frequência absoluta. Com estas definições, avaliações estatísticas das relações médicas já conhecidas ou ainda desconhecidas pode ser levada a cabo usando os dados dos pacientes com diagnósticos confirmados"

9.7.3 CADIAG-2: Inferência

A partir das relações Paciente/Sintomas e Paciente/Combinações de Sintomas e das 8 relações difusas atrás apresentadas e representativas do conhecimento médico, o CADIAG-2 realiza 12 operações de composição:

- Estas composições são realizadas pela RCI, cuja aplicação "equivale" a vários *modus ponens generalizados* (MPG):

Premissa: $x \text{ é } \tilde{A}'$
Implicação: Se $x \text{ é } \tilde{A}$, então $y \text{ é } \tilde{B}$
Conclusão: $y \text{ é } \tilde{B}$ (no grau z)

Composição de Relações Difusas segundo Zadeh (repetição):

$$R_1 \circ R_2 = \left\{ \left[(x, z), \max_y \{ \min \{ \mu_{R_1}(x, y), \mu_{R_2}(y, z) \} \} \right] \mid x \in X, y \in Y, z \in Z \right\}$$

As 12 composições de relações descrevem-se resumidamente em seguida:

9.7.3 CADIAG-2: Inferência

Composições 1,2 e 3: Sintomas / Diagnósticos

Com estes sintomas
deve ser a doença x

1. Composição $S_i D_j$ (hipótese pelos sintomas presentes)

Obtém-se compondo a relação doentes/sintomas com a relação sintomas/doenças usando $\mu_{\text{confirmabilidade}}$ (daí o c que figura como sobrescrito de R_{SD})

$$R_{PD}^1 = R_{PS} \circ R_{SD}^c$$

$$\mu_{R_{PD}^1}(P_q, D_j) = \max_{S_i} \min [\mu_{R_{PS}}(P_q, S_i); \mu_{R_{SD}^c}(S_i, D_j)]$$

Com estes sintomas não
deve ser a doença x

2. Composição $S_i D_j$ (exclusão pelos sintomas presentes)

$$R_{PD}^2 = R_{PS} \circ (1 - R_{SD}^c)$$

$$\mu_{R_{PD}^2}(P_q, D_j) = \max_{S_i} \min [\mu_{R_{PS}}(P_q, S_i); 1 - \mu_{R_{SD}^c}(S_i, D_j)]$$

Porquê $1 - \mu$?



Porquê μ_c (e não μ_o) ? Na composição das relações $R1$ e $R2$ é usado μ_c e não μ_o uma vez que se está a compor **doentes/sintomas** com **sintomas/doenças** o que significa que se trata de uma possibilidade *a posteriori*: ela representa a hipótese ou exclusão de diagnósticos a partir dos sintomas observados e esse grau de confirmação é representado por μ_c

9.7.3 CADIAG-2: Inferência

Porquê $1-\mu_c$ na composição de R2 ?

1. O grau de verdade de *not A* é dado por

$$v(\text{not "u is A"}) = v(\neg A) = \neg v(A) = 1-v(A)$$

2. A definição clássica da implicação é

$$(p \Rightarrow q) = (\neg p \vee q)$$

3. Relação R2 = Exclusão de diagnósticos pelos sintomas presentes: inferir quais os diagnósticos que não são possíveis devido aos sintomas que se observam. Portanto, pretende-se calcular o grau de verdade de

$$\begin{array}{lcl} \text{Segundo 1.} & \left\{ \begin{array}{l} v(A) \Rightarrow \neg v(B) = \\ = \neg v(A) \vee \neg v(B) = \end{array} \right. & \text{Segundo 2.} \\ \text{Segundo 2.} & \left\{ \begin{array}{l} = \neg v(A) \vee v(\neg B) = \\ = v(A) \Rightarrow v(\neg B) = \end{array} \right. & \\ \text{Segundo 1.} & \left\{ \begin{array}{l} = v(A) \Rightarrow 1-v(B) = \\ = v(\text{"u is A"}) \Rightarrow v(\text{"z is not B"}) \end{array} \right. & \end{array}$$

9.7.3 CADIAG-2: Inferência

Se fosse a doença x
deveriam existir certos
sintomas ...

3. Composição $S_i D_j$ (exclusão pelos sintomas ausentes)

Obtém-se compondo a relação doentes/sintomas com a relação sintomas/doenças usando $\mu_{\text{ocorrência}}$ (daí o *o* que figura como sobrescrito de R_{SD})

$$R_{PD}^3 = (1 - R_{PS}) \circ R_{SD}^o$$

$$\mu_{R_{PD}^3}(P_q, D_j) = \max_{S_i} \min [1 - \mu_{R_{PS}}(P_q, S_i); \mu_{R_{SD}^o}(S_i, D_j)]$$

R3 resulta de doentes-sintomas e sintomas-doenças mas usando $1 - \mu_{PS}$ e μ_o .

Porquê μ_o ? Pretendem excluir-se diagnósticos que não são possíveis porque há sintomas que não se observam. Portanto, pretende calcular-se o grau de verdade de

$$\begin{aligned} \neg v(A) \Rightarrow \neg v(B) &= \\ &= \neg v(\neg A) \vee \neg v(B) = v(A) \vee v(\neg B) = v(\neg B) \vee v(A) = v(B) \Rightarrow v(A) \end{aligned}$$

Em suma: como $(\neg v(A) \Rightarrow \neg v(B)) = (v(B) \Rightarrow v(A))$ deve usar-se μ_o porque é ele que expressa as ligações no sentido doença \rightarrow sintomas (i.e. $B \rightarrow A$).

Porquê $1 - \mu_{PS}$? Em que grau é que um sintoma está ausente? Está presente no grau μ_{PS} , logo está ausente no grau $1 - \mu_{PS}$... e portanto usa-se $1 - \mu_{PS}$ para expressar um grau de ausência em vez de presença.

9.7.3 CADIAG-2: Inferência

A composição de relações 4 a 12 baseia-se em processos idênticos aos analisados:

- 4, 5 e 6 - é definida de forma idêntica mas a partir de R_{PqSCI} e de R_{SCiDj} (combinações de sintomas / diagnósticos)
- 7, 8 e 9 é definida de forma idêntica mas a partir de R_{PqSI} e de R_{SCiSCj} (sintomas / sintomas). Destina-se a completar o quadro (*pattern*) de sintomas de cada paciente
- A composição de relações 10, 11 e 12 é definida de forma idêntica mas a partir de R_{PqDI} e de R_{DiDj} (diagnósticos / diagnósticos) (tem a ver com o processo de diagnóstico diferencial)

Diagnóstico confirmado:

- μ_{PD} obtido pela inferência 1 ou 4, tem o valor 1 ou ...
- μ_{PD} obtido pela inferência 10 tem o valor 1

Diagnóstico excluído:

- μ_{PD} obtido pelas inferências 2 ou 3 ou 5 ou 6 tem o valor 1 ou...
- μ_{PD} obtido pelas inferências 11 ou 12 tem o valor 1

Para mais pormenores ver bibliografia indicada no início da secção 6.7

9.8 Match no Fuzzy CLIPS

9.8 Fuzzy CLIPS

Uma versão difusa do CLIPS chamada **Fuzzy CLIPS** foi desenvolvida no NRC - *National Research Center* - Canadá (*freeware* para fins académicos)

- No Fuzzy CLIPS uma regra pode lidar com valores crespos, difusos e CFs

Porém como determinar o *match* entre um facto e a premissa de uma regra quando ambos são representados por conjuntos difusos ?

Exemplo

SE "rendimento baixo" ENTÃO "crédito baixo"

Qual o crédito a conceder se o indivíduo tiver um "rendimento médio"?

Há que calcular uma medida da semelhança entre baixo e médio !!!

No Fuzzy CLIPS esta semelhança é determinada com base no trabalho de Cayrol, Farenni e Prade, baseando-se nas medidas difusas Possibilidade e Necessidade, como se segue:

9.8 Match no Fuzzy CLIPS

As expressões base são as seguintes:

$$\text{Se } N(F\beta | F\alpha) > 0.5 \quad S = P(F\beta | F\alpha) \quad (1)$$

$$\text{Senão} \quad S = (N(F\beta | F\alpha) + 0.5) * P(F\beta | F\alpha) \quad (2)$$

com S = Semelhança entre $F\alpha$ e $F\alpha$, P = Possibilidade, N = Necessariedade
e P e N são definidas por

$$P(F\beta | F\alpha) = \max(\min(\mu_{F\beta}(u), \mu_{F\alpha}(u)) \quad \forall u \in U \quad (3)$$

$$N(F\beta | F\alpha) = 1 - P(F\beta | F\alpha) \quad (4)$$


$$\mu_{\neg F\alpha} = 1 - \mu_{F\alpha} \quad (5)$$

Exemplos

Caso 1

Os conjuntos α e β não se sobrepõem

É o caso de se querer comparar p.e.
"água quente" (facto) com "água fria"
(premissa de uma regra)



9.8 Match no Fuzzy CLIPS

De (4) temos que $N(F_\beta | F_\alpha) = 1 - P(F_{\alpha\beta} | F_\alpha)$

Na figura representou-se a verde $F_{\alpha\beta}$ atendendo a que através de (5), $\mu_{\alpha\beta} = 1 - \mu_{F_\beta}$.

De (3) temos que $P(F_\beta | F_\alpha) = \max(\min(\mu_{F_\beta}(u), \mu_{F_\alpha}(u)))$

que aplicado ao caso presente se transforma em $P(F_{\alpha\beta} | F_\alpha) = \max(\min(\mu_{F_{\alpha\beta}}(u), \mu_{F_\alpha}(u)))$.

Este máximo encontra-se assinalado na figura e tem o valor 1.

Logo, $P(F_{\alpha\beta} | F_\alpha) = 1$.

Donde, de (4), $N(F_\beta | F_\alpha) = 1 - 1 = 0$.

Como $N=0$ é < 0.5 , a semelhança entre F_α e F_β é dada por (2):


$$S = (N(F_\beta | F_\alpha) + 0.5) * P(F_\beta | F_\alpha)$$

Segundo (3), $P(F_\beta | F_\alpha) = \max(\min(\mu_{F_\beta}(u), \mu_{F_\alpha}(u)))$. Mas como F_α e F_β não têm pontos comuns, $P(F_\beta | F_\alpha) = 0$

Então $S=0$ (conforme esperado) por se tratar de um produto.

Caso 1


Os conjuntos α e β não se sobrepõem



9.8 Match no Fuzzy CLIPS

Caso 2

Os conjuntos α e β têm bases que se sobrepõem em menos de 50%



De (3) $P(F_{\alpha\beta} | F_{\alpha}) = \max(\min(\mu_{F_{\alpha\beta}}(u), \mu_{F_{\alpha}}(u))$ e vemos que agora os *min* continuam a seguir μ de $F_{\alpha\beta}$ donde o *max* é 1 e portanto $N(F_{\beta} | F_{\alpha}) = 0$.

Porém, agora α e β cruzam-se, donde, supondo que o cruzamento se dá em $A=0,4$, resulta $P(F_{\beta} | F_{\alpha}) = \max(\min(\mu_{F_{\beta}}(u), \mu_{F_{\alpha}}(u)) = 0.4$

Como $N < 0.5$, a fórmula a aplicar é a mesma do exemplo anterior:

$$S = (N(F_{\beta} | F_{\alpha}) + 0.5) * P(F_{\beta} | F_{\alpha})$$

$$\text{Donde } S = (0 + 0.5) * 0.4 = 0.2$$

Para mais pormenores sobre o Fuzzy CLIPS, em particular os métodos de combinação de incerteza (CFs e valores difusos) ver o User's Guide