Instituto Superior de Engenharia de Coimbra

LICENCIATURA EM ENGENHARIA INFORMÁTICA
INTELIGÊNCIA COMPUTACIONAL
23/24

Redes de "Deep Learning"
Exercícios

---

1. Indique se as seguintes afirmações são verdadeiras ou falsas e **justifique, indicando um exemplo concreto**:
   a) O número de parâmetros de uma rede CNN é bastante superior a uma rede MLP (densa) com o mesmo número de camadas e para classificação de imagens com a mesma dimensão.
   b) Sem a aplicação de um operador de "padding" a dimensão de um "feature map" iguala sempre a dimensão da imagem de entrada.
   c) A aplicação do operador "Full padding" gera um "feature map" de menor dimensão que a imagem de entrada.
   d) Um valor de "stride" de 2 gera "features maps" com o dobro dos parâmetros.
   e) Uma rede CNN não é treinada por um algoritmo do tipo gradiente, pois os filtros e seus parâmetros são determinados apenas com base em conhecimento pericial.

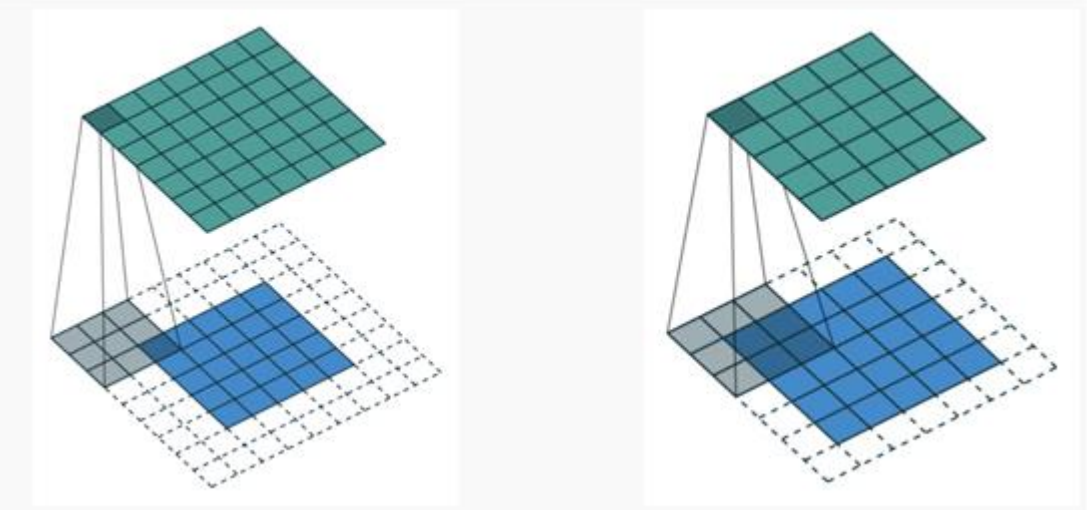

Figura 1. Full padding (esquerda) vs Same padding (direita) [1] : "Full padding" – Aumenta a dimensão da saída (feature map) relativamente à entrada (imagem), para garantir que todos os pixéis sejam "visitados" o mesmo número de vezes ; "Same padding" – garante que o feature map resultante tenha a mesma dimensão do mapa de entrada;

2. Existem normalmente quatro operações numa rede CNN: operação de convolução, aplicação de uma função de ativação não linear (usualmente a função "Relu"), operação de "pooling" e finalmente o processo de classificação com uma rede densa "full connected".

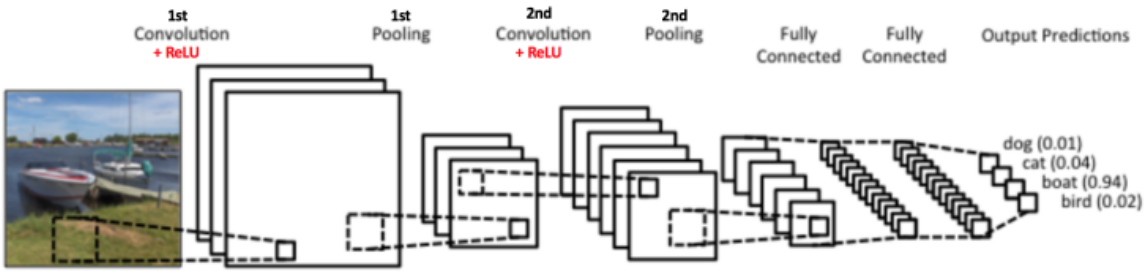

Figura 2. Exemplo de uma rede CNN [1]

Relativamente ao processo de convolução, considere uma imagem binária de 5x5:

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Considere a aplicação do seguinte filtro 3x3:

1	0	1
0	1	0
1	0	1

a) Determine o "feature map" resultante do processo de convolução considerando:
   - Stride = 1 e sem "padding"
   - Stride = 1 e "Same padding".
   - Stride = 1 e "Full padding".

b) Aplique a função “Relu” ao feature map criado anteriormente
   - com “bias”=0.
   - Com “bias”=2.

c) Aplique o operador “Max Pooling” usando uma janela de 2×2 ao feature map resultante da alínea a).

d) Aplique o operador “Average Pooling” usando uma janela de 2×2 ao feature map resultante da alínea a).

3. Relativamente à arquitetura da rede da Figura 4, responda às seguintes questões:

a) Qual a dimensão da imagem e número de canais?

b) Quantas camadas de convolução existem?

c) Quantos filtros existem por camada? Comente o critério para definição do número de filtros nas camadas sucessivas.

d) Qual o operador de pooling e dimensão da janela?

e) Qual a arquitetura e funções de ativação da rede de classificação?

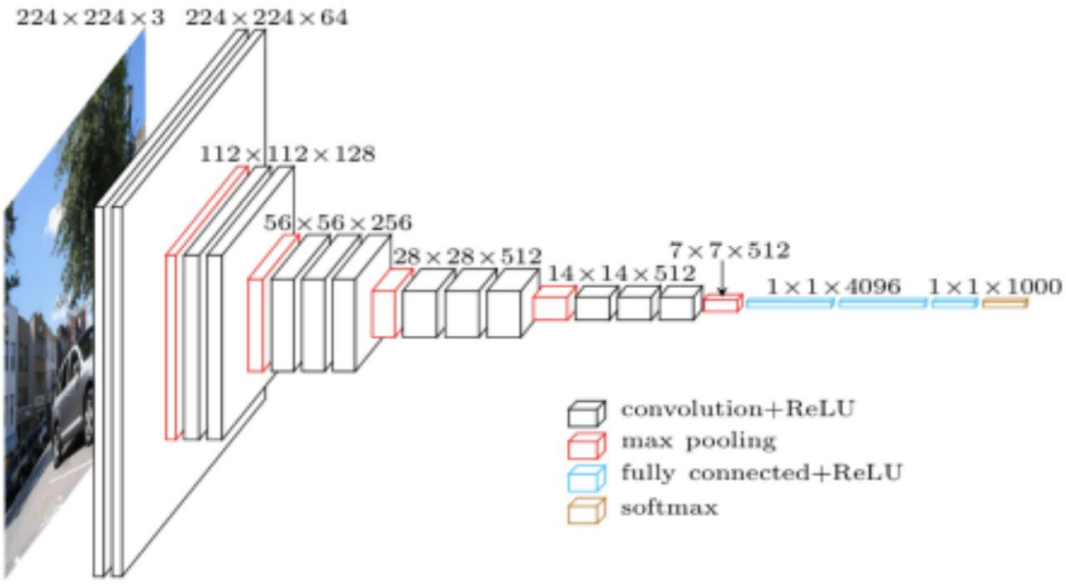

(a)

A rede tem a seguinte estrutura:

```
model = Sequential()

model.add(Conv2D(input_shape=(224,224,3),filters=64,kernel_size=(3,3),padding="same",
activation="relu"))
```

```
model.add(Conv2D(filters=64,kernel_size=(3,3),padding="same", activation="relu"))
model.add(MaxPool2D(pool_size=(2,2),strides=(2,2)))

model.add(Conv2D(filters=128, kernel_size=(3,3), padding="same", activation="relu"))
model.add(Conv2D(filters=128, kernel_size=(3,3), padding="same", activation="relu"))
model.add(MaxPool2D(pool_size=(2,2),strides=(2,2)))

model.add(Conv2D(filters=256, kernel_size=(3,3), padding="same", activation="relu"))
model.add(Conv2D(filters=256, kernel_size=(3,3), padding="same", activation="relu"))
model.add(Conv2D(filters=256, kernel_size=(3,3), padding="same", activation="relu"))
model.add(MaxPool2D(pool_size=(2,2),strides=(2,2)))

model.add(Conv2D(filters=512, kernel_size=(3,3), padding="same", activation="relu"))
model.add(Conv2D(filters=512, kernel_size=(3,3), padding="same", activation="relu"))
model.add(Conv2D(filters=512, kernel_size=(3,3), padding="same", activation="relu"))
model.add(MaxPool2D(pool_size=(2,2),strides=(2,2)))

model.add(Conv2D(filters=512, kernel_size=(3,3), padding="same", activation="relu"))
model.add(Conv2D(filters=512, kernel_size=(3,3), padding="same", activation="relu"))
model.add(Conv2D(filters=512, kernel_size=(3,3), padding="same", activation="relu"))
model.add(MaxPool2D(pool_size=(2,2),strides=(2,2)))

model.add(Flatten())
model.add(Dense(units=4096,activation="relu"))
model.add(Dense(units=4096,activation="relu"))
model.add(Dense(units=1000, activation="softmax"))
```

Figura 3. Rede VGG 16 para ImageNet 1000 classes [2]

4. Pretende-se a classificação de imagens de dimensão 150 × 100 RGB (3 canais).
   Considere uma rede CNN com 200 filtros 5x5, com stride de 1 e 'same padding" (cria feature maps de 150x100).
   a) Calcule o número de parâmetros para a primeira camada de convolução.
   b) Compare com o número de parâmetros de uma camada de uma rede densa "full connected" com o mesmo número de neurónios (15000) na primeira camada.

Soluções:

P2

a) *A convolução de uma uma imgem 5x5 com um filtro 3x3, sem padding e com stride=1, gera uma mapa de 3x3. O primeiro elemento é calculado por:*
*1*1+1*0+1*1 + 0*0+1*1+1*0 + 0*1+0*0+1*1 = 4, ….*

4	3	4
2	4	3
2	3	4

b) *Relu com bias=0*

4	3	4
2	4	3
2	3	4

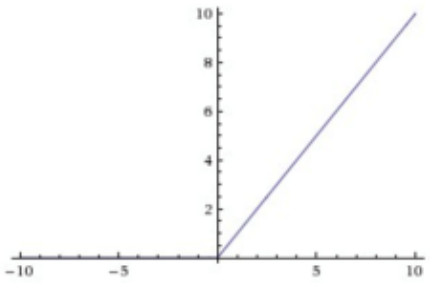

c) *MaxPooling 2x2 (slide=1):*
O primeiro elemento corresponde max(4,3,2,4),….e assim sucessivamente, obtemos:

4	4
4	4

P3

a) Qual a dimensão da imagem e número de canais?
   224x224 e 3 canais
b) Quantas camadas de convolução existem?
   2+2+3+3+3=13
c) Quantos filtros existem por camada? Comente o critério para definição do número de filtros nas camadas sucessivas.
   64,64,128,128,256,256,256,512,512,512, 512,512,512
   3 blocos de convolução. O número de filtros aumenta de forma a representar padrões mais complexos.
d) Qual o operador de pooling e dimensão da janela?
   Maxpooling, com janela de 2x2 e stride=2
e) Qual a arquitetura e funções de ativação da rede de classificação?
   Número de entradas = 25088; Duas camadas densas de 4096 neurónios e função "relu"; 1000 saídas e função de ativação softmax.

P4

a) Com filtros 5x5 produzindo 200 features maps, o número de parâmetros = (5×5×3+1) ×200 (com bias) = **15 200**

b) Para uma rede densa:
   Número de entradas = 150*100*3
   Número de neurónios = 150*100.
   Para uma "fully connected layer", o número total de parâmetros sem bias =(150*100*3)* (150*100)=**675 000 000**!!

Referências:

[1] https://www.mathworks.com/help/deeplearning/ref/vgg16.html
[2] https://keras.io/api/applications/vgg/