

- **Exercício 01**

Num processo de diagnóstico médico, numa população de 2000 indivíduos, o método automático de classificação (diagnóstico positivo vs negativo) apresentou os seguintes resultados, expressos na matriz de confusão:

		<b>Real</b>	
	<i>Tamanho da população</i>	Condição Positiva	Condição Negativa
<b>Predição</b>	Predição Positiva	<b>20</b>	<b>170</b>
	Predição Negativa	<b>10</b>	<b>1800</b>

- Calcule a “accuracy” (exatidão/acurácia), precisão, sensibilidade (recall) e especificidade do classificador.
- Comente a qualidade do sistema de diagnóstico.

- **Exercício 02**

Está a resolver um problema de classificação binária com uma classe altamente desequilibrada, onde a classe maioritária é observada 99% das vezes nos dados de treino. O modelo, após o treino, apresenta 99% de “accuracy” no conjunto de teste.

- Qual ou quais das afirmações considera verdadeira e justifique:
  - A métrica de “accuracy” avalia corretamente o desempenho deste classificador.
  - A métrica de “accuracy” não deve ser usada, deve-se considerar a “precision”.
  - A métrica de “accuracy” não deve ser usada, as métricas de precisão e recall devem ser ambas avaliadas.

- **Exercício 03**

Pretende desenvolver uma rede neuronal para prever o número de visualizações de artigos num blog. A sua análise deve ser baseada em características tais como autor, número de artigos escritos pelo mesmo autor ou outras a identificar.

- Que outras “features” deverá considerar? Justifique.
- Como formaria o conjunto de treino e teste? Como procederia ao treino da rede neuronal?
- Qual da(s) seguintes métrica(s) de avaliação escolheria para avaliar o modelo obtido: MSE, Precisão ou F1 score? Justifique.

### Métricas para Classificação

- **Matriz de Confusão:**

		<u>Real</u>	
		Condição Positiva	Condição Negativa
<u>Predição</u>	Predição Positiva	<b>TP</b>	<b>FP</b>
	Predição Negativa	<b>FN</b>	<b>TN</b>

Prevalência =  $\Sigma$  Condições positivas /  $\Sigma$  População Total

Taxa de Acerto (ACC-Accuracy) =  $(TP+TN)/\text{Tamanho da População}$

- **Métricas Lidas a partir da Matriz:**

Precisão ou PPV-“Positive Predicted Value” =  $TP/(TP+FP)$

False discovery rate (FDR) =  $FP/(TP+FP)$

False omission rate (FOR) =  $FN/(FN+TN)$

Negative predictive value (NPV) =  $TN/(FN+TN)$

Sensibilidade ou Recall (TPR-True Positive Rate) =  $TP/(TP+FN)$

False negative rate (FNR)=FN/ (TP+FN)

False positive rate (FPR)=FP/(FP+TN)

Especificidade (TNR-True Negative Rate)=TN/FP+TN

- **Métricas Combinadas:**

F-Measure=2\*(Precison\*Recall)/(Precision+Recall)

F1 score=2\*TP/(2\*TP+FP+FN) – *media harmónica entre precisão e recall*

Positive likelihood ratio (LR+)=TPR/FPR

Negative likelihood ratio (LR-)=FNR/TN

## Métricas para Regressão

As métricas de regressão envolvem o cálculo do erro para avaliar a capacidade preditiva do modelo:

- Mean absolute error

$$\text{MAE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} |y_i - \hat{y}_i|.$$

- Mean Squared Error

$$\text{MSE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (y_i - \hat{y}_i)^2.$$

- Root Mean Squared Error

$$\text{RMSE} = \sqrt{\frac{\sum_{i=1}^N \|\hat{y}_i - y_i\|_2^2}{N}}$$

- R<sup>2</sup> score

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$